

Pipeline MLOps

Evaluación de riesgo crediticio en la Nube

Grupo 2

Sebastian Guevara

Diego Medina

Diego Quiñones




Los bancos reciben miles de **solicitudes de préstamo** al día

Riesgo de impago:
cliente puede no pagar en el tiempo establecido




Decidir manualmente si aprobar el préstamo es **imposible**

Modelos de ML
aprenden de datos históricos para predecir comportamiento de pago



El cuello de botella:



- Entrenar sobre **miles de registros y múltiples variables** toma horas.
- Probar **múltiples configuraciones** multiplica el tiempo exponencialmente.

Pregunta de investigación:



¿Cómo reducir el tiempo de entrenamiento sobre datasets financieros de alta dimensionalidad **sin perder calidad predictiva?**



Fuente: Home Credit Default Risk - Kaggle

356 255

Registros

122

Variables

11:1Ratio de
clases**8%**Clase positiva
(impago)

Hallazgos Preliminares

- **Anomalía en 'DAYS_EMPLOYED'**
Valor centinela 365 243 convertido en NaN durante la carga.
- **Alta tasa de valores faltantes**
55 % de columnas con nulos se concentran en atributos de inmueble.

**Dimensiones
post limpieza****245 998**

Train

48 743

Test

61 500

Validation

Fase 1 — Carga y corrección

Leer CSVs , Corregir DAYS_EMPLOYED

Fase 2 — Limpieza de datos

Eliminar filas >50% vacíos, columnas >60% vacíos

Fase 3 — Preprocesamiento

Texto

→ “Desconocido”, category

Hilo 1

Num. Continuo

vacíos= mediana, RobustScaler

Hilo 2

Num. Entero

vacíos= mediana

Hilo 3

Fase 4 — División estratificada

80% entrenamiento · 20% validación

8% impagos c/u

Fase 5 — Entrenamiento

LightGBM x4

varía LR y
complejidad




XGBoost x4


varía LR y
complejidad

Secuencial

Paralelismo de tareas (Joblib)


Paralelismo de datos (OpenMP)






Proyección: con más núcleos el speedup sería mayor

Máquina Virtual




DockerHub

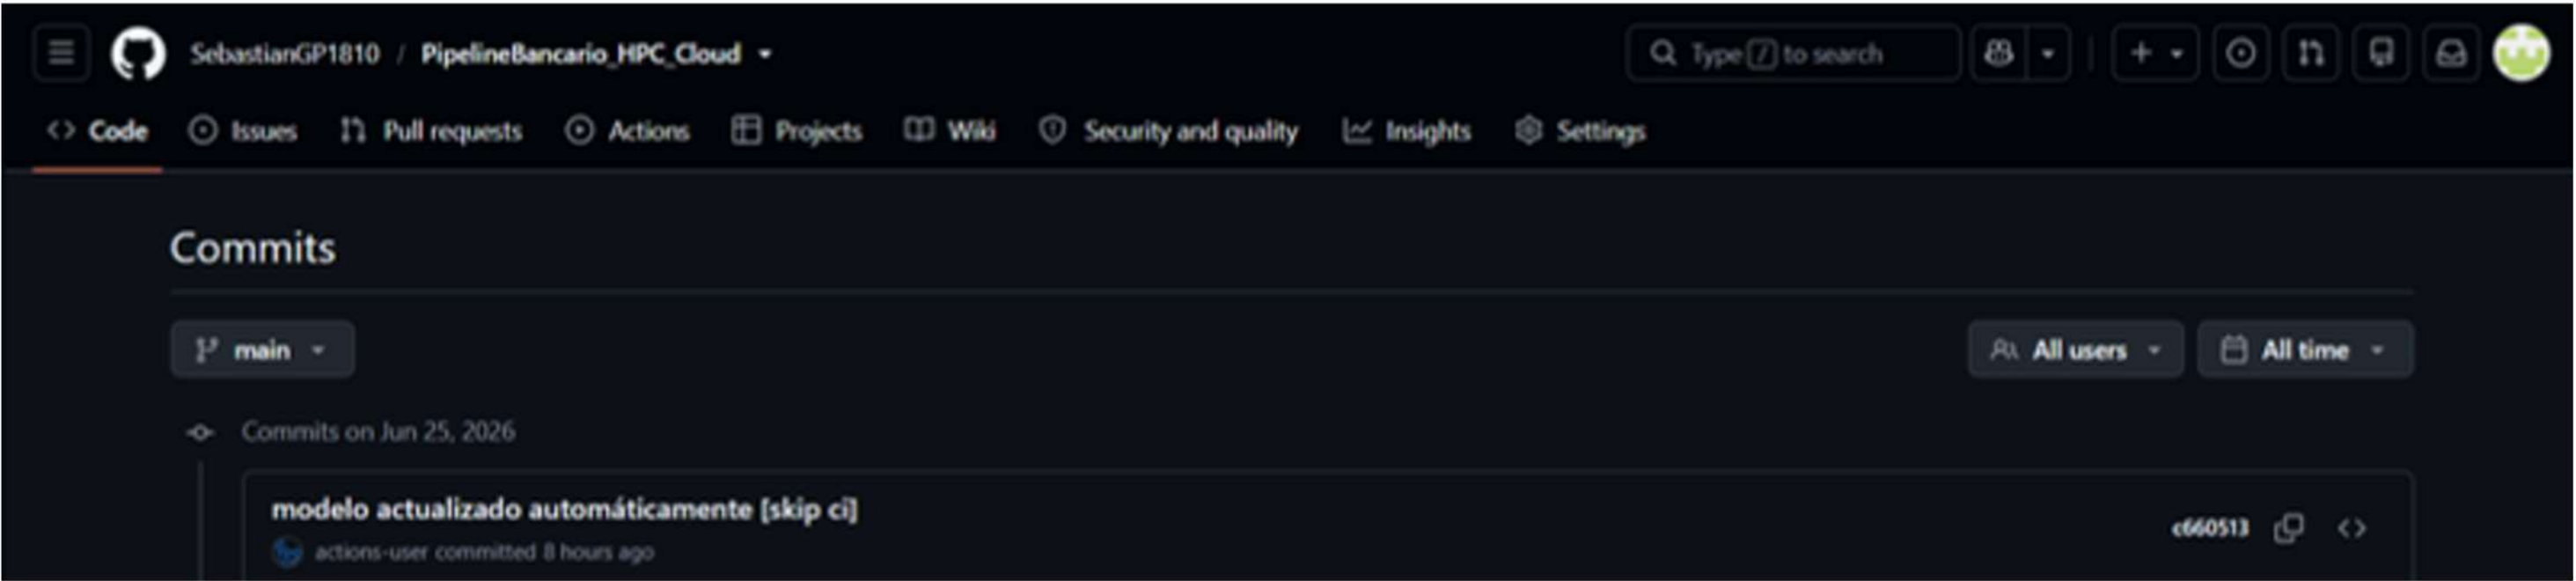
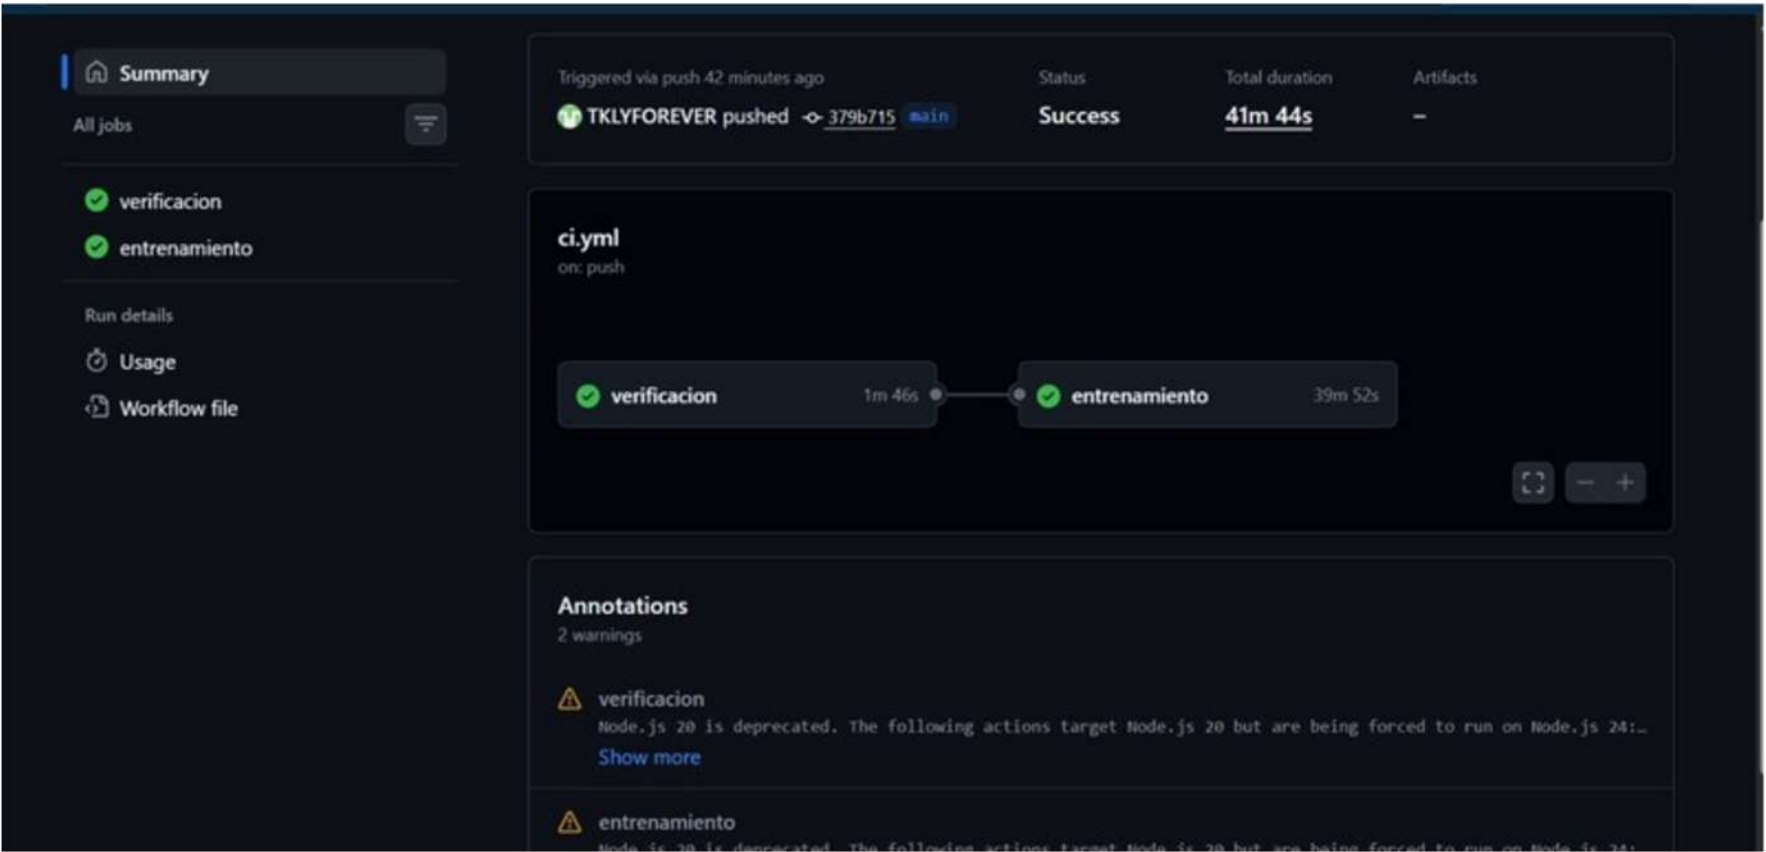


Puerto: 8501



Puerto: 8888





Git LFS


Para datasets
grandes

Contención

2 núcleos
físicos

Mejoras

Más núcleos
Kubernetes
SMOTE



CONCLUSIONES

Se lograron realizar los objetivos del proyecto

- Speedup global 3.36x
 - LGB-1 mejor modelo (AUC 0.7597)
 - Pipeline MLOps completo funcionando
 - Reproducible en cualquier máquina con Docker
 - Desplegado en Azure con interfaz de usuario
-
- GitHub: github.com/SebastianGP1810/PipelineBancario_HPC_Cloud
 - DockerHub: [rodie916/pipeline-bancario:latest](https://hub.docker.com/r/rodie916/pipeline-bancario)